PlantãoSeguro: Entrega 2 (dados, análise, solução de IA e prova de conceito)

Disciplina: Hands On – Aplicação de IA nos negócios (Mackenzie), Prof. Fabio Versolatto. **Grupo:** Victor Jordão, Roberval Silva, Guilherme Tarrago, Sergio Freitas, Lucas Barbosa e Plinio Camilo. **Entrega:** 31/10/2026, versão 2 (revisada depois de conferir o feedback da Entrega 1). **Código, dados e documentos:** github.com/vhjordao/handson_plantaoseg.

Resumo. Hospitais ainda cobrem plantões por canais manuais e opacos. O PlantãoSeguro lê o pedido da vaga em texto livre e devolve os médicos elegíveis, ordenados e com o motivo de cada um: **a IA recomenda, o humano decide**. Esta entrega traz uma **prova de conceito que roda** (Python, linha de comando, 176 testes automáticos e CI verde) sobre **dados sintéticos** de um pronto-socorro de hospitais privados. Em simulação, o fluxo recomendado preenche a vaga em menos da metade do tempo e não viola a jornada, mas **concentra as ofertas em poucos médicos**, e esse é o principal risco a tratar. O Gemini está desenhado e protegido por testes, mas **não foi exercitado contra o serviço real**.

47 min
tempo médio até preencher a vaga
processo manual: 110 min (57% a menos); a meta da Entrega 1 era 50%

71,2%
chance de sucesso no top-5
baseline heurístico: 67,7%; oráculo: 75,8%

0
violações de jornada nas recomendações
processo manual: 1,3% dos aceites

50,7%
lugares do top-5 ocupados pelos 10% mais recomendados
processo manual: 31,1%; piora, risco a mitigar

Frase-síntese: queremos utilizar IA para recomendar e explicar quais médicos chamar para cada plantão de pronto-socorro, a fim de reduzir o tempo de cobertura sem violar a jornada nem as regras do CFM, beneficiando coordenadores de escala e médicos de hospitais privados, medindo o sucesso pelo tempo até preencher a vaga, pela qualidade do ranking contra um baseline, pelas violações de jornada (meta zero) e pela concentração das ofertas.

1. O problema, o segmento e o que mudou desde a Entrega 1

A Entrega 1 mostrou que plantões são cobertos por canais manuais e opacos, o que atrasa o preenchimento, aumenta o risco assistencial e expõe as partes a riscos jurídicos novos. Quatro dores guiam esta entrega, e cada parte da solução responde a uma delas:

Dor da Entrega 1	O que a PoC faz	Evidência (simulação)	Situação
1. Vaga descoberta, percebida tarde	Lê o pedido, filtra e ranqueia em segundos; prever vagas em risco fica para depois	Tempo médio até preencher: 110 para 47 min; ofertas por vaga: 3,31 para 1,32	Recomendação construída; previsão é evolução futura
2. Seleção opaca	Motivo por candidato, regra que barrou cada excluído, trilha com hash e pagamento fora do ranking	Testes de explicação, auditoria e neutralidade econômica (na CI)	Construído
3. Fadiga sem controle	Filtro de jornada (24 h contínuas, 11 h de descanso) e alerta de carga	Violações: 0, contra 1,3% dos aceites no processo manual	Construído
4. Pagamento sem rastro	Fora do núcleo; o rastro de pagamentos é evolução futura (e a Res. CFM 2.462 está suspensa)	n/d	Não construído

Segmento (ADR 0001). Pronto-socorro de hospitais privados, plantão noturno de 12 h e de fim de semana, clínica médica e pediatria. Um recorte só mantém os indicadores comparáveis (todos valem para o mesmo tipo de vaga) e o simulador simples; ampliar é mudar um parâmetro. Que noite e fim de semana sejam mais difíceis de cobrir é uma **hipótese**: não há dado nacional, e as entrevistas vão testá-la. Diagnóstico, prontuário e receita com validade legal ficam **fora** do escopo.

Como respondemos ao feedback da Entrega 1

Pedido do professor	O que fizemos	Onde
Definir o segmento inicial	O recorte acima, com a hipótese marcada como tal	Seção 1
Separar o essencial do complementar	Núcleo: recomendação de elegíveis e explicação. Cascata, contestação, check-in, pagamento e previsão de vagas ficam como evolução futura	Seção 5
Justificar as metas com linha de base e ajustá-las aos dados	As seis metas da Entrega 1 ganharam linha de base (o processo manual simulado) e resultado do fluxo recomendado; as que os dados não permitem medir dizem por quê	Seção 7
Conferir os textos oficiais vigentes e o que depende de análise jurídica	Três resoluções do CFM lidas em 30/10, com vigência, obrigações para a plataforma e sete pendências para o jurídico; duas correções à Entrega 1	Seção 6

2. Dados

Origem e por quê. Ainda não há dado real nem entrevistas, e o repositório é público. Por isso criamos um **mundo simulado**: três hospitais privados fictícios de uma rede, 300 médicos e 12 meses (de 01/10/2025 a 30/09/2026) de vagas e de ofertas feitas por um "processo manual", em que a coordenação sorteia quem chamar sem checar disponibilidade nem jornada. O recorte desse mundo (pronto-socorro de hospitais privados, plantão noturno e de fim de semana) foi **sugestão do Victor**; o gerador foi construído em conjunto com o Claude Code. Nome, CRM e telefone são fictícios e marcados `SIM`.

Tabela	Linhas	Conteúdo	Em produção viria de
Médicos	300	Especialidade, raio, preferência de período, zona	Cadastro e credenciamento do hospital
Janelas de disponibilidade	3.391	Janelas livres e dias bloqueados	Informadas pelo médico
Vagas	2.448	Noturnas todos os dias; diurnas só no fim de semana	Pedido da coordenação
Ofertas	7.555	Quem foi chamado, resposta e comparecimento	A própria plataforma e o check-in
Pedidos em texto livre	400	5 estilos, com gabarito; 15% adversariais	Texto digitado pela coordenação
Valor do plantão	2.448	Tabela **separada**, fora do ranking	Financeiro do hospital

Variáveis. O dicionário de dados (v0.2) dá a cada coluna um **papel**: variável do ranking, auditoria de viés (gênero, faixa etária e zona), restrito econômico, dado pessoal simulado ou gabarito do simulador. O ranking usa **sete variáveis**, todas calculadas só com o que já era conhecido antes de cada oferta:

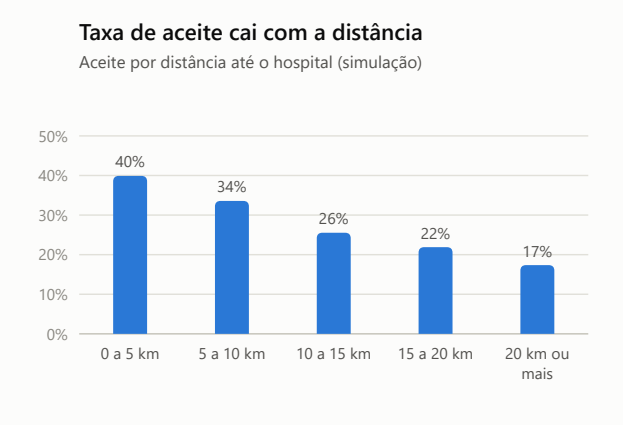
Variável	O que mede	Por que entra
Especialidade	1 se é a principal, 0,5 se só a secundária coincide	É o que a vaga exige
Distância	km em linha reta até o hospital	Quem mora longe recusa mais: aceite de 39,9% até 5 km e de 17,4% a 20 km ou mais
Cobertura da vaga	Horas da vaga cobertas pela disponibilidade	Maior correlação com o sucesso (0,370)
Taxa de aceite (90 dias)	Aceites sobre ofertas com resultado conhecido	Histórico recente de resposta
Taxa de comparecimento (90 dias)	Comparecimentos sobre plantões aceitos	Confiabilidade para o plantão acontecer
Horas desde o último plantão	Folga até a vaga, limitada a 7 dias	O descanso pesa: aceite de 22,3% quando o plantão é colado a outro e de 42,4% com 72 h ou mais
Preferência de período	1 se a preferência do médico coincide com a vaga	Em vaga noturna, aceite de 37,0% quando coincide e de 18,1% quando não

Tratamento e qualidade. O futuro não vaza: cada variável usa só o que era conhecido antes da oferta (testado). O gerador aplica **8 regras de qualidade** (integridade, domínios, datas, unicidade, coerência, sobreposição, ausência de dado real e cobertura do segmento), com **zero violações** (relatório). A mesma semente gera os mesmos arquivos: a CI, em Linux, reproduziu os checksums da máquina do autor, em Windows.

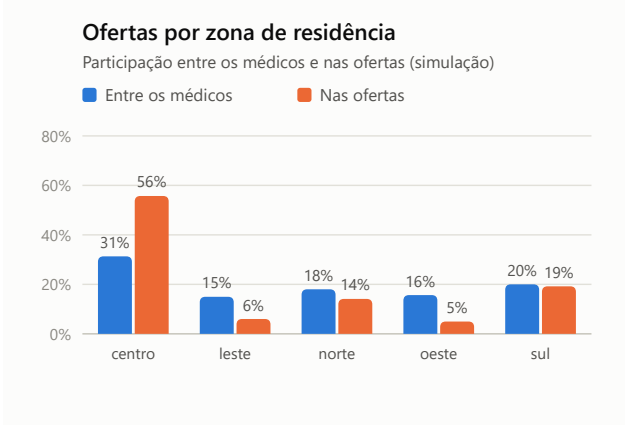
Limites. Os parâmetros do simulador são premissas do grupo, sem fonte externa; só se observa a resposta de quem foi chamado (viés de seleção); e o tempo até preencher a vaga é simulado: serve para comparar métodos, não como linha de base real. No processo manual simulado há 3,09 ofertas por vaga, 30,8% de aceite, 4,8% de vagas sem cobertura e 1,3% de aceites que violam a jornada.

3. Análise dos dados

A análise exploratória confere se o simulador se comporta como as premissas dizem e mostra onde mora o risco do ranking. Como os dados são sintéticos, ela não descobre fatos do mundo real.



Taxa de aceite por faixa de distância (simulação)



Exposição das ofertas por zona de residência (simulação)

- **O aceite cai com a distância:** 39,9% de 0 a 5 km e 17,4% a 20 km ou mais. Em vaga noturna, quando a preferência de período coincide o aceite vai a 37,0%, contra 18,1% quando não coincide.
- **Descanso:** 22,3% de aceite quando o plantão é colado a outro e 42,4% com 72 a 167 h livres. Os plantões duram 12 h e começam às 7h ou às 19h, então o intervalo entre dois deles é 0 h (colados) ou de 12 h ou mais: a regra das 11 h de descanso quase nunca é a que barra; o limite de 24 h contínuas, sim.
- **Correlação com o sucesso:** cobertura da vaga (0,370), preferência de período (0,200) e distância (−0,156) lideram. A carga recente tem correlação positiva (0,069), por confundimento (quem é confiável aceita mais), o que motivou tirá-la do ranking.
- **Exposição desigual (o risco do exemplo de recrutamento da aula: reproduzir o viés do histórico):** a zona central tem 31,3% dos médicos e recebe 55,7% das ofertas; leste e oeste recebem 0,40 e 0,32 do esperado. Entre 35 e 44 anos a razão é 1,49 e, a partir de 55, 0,39; por gênero é praticamente 1. O aceite do grupo quase não varia por gênero (30,2% a 31,4%) e varia por zona (23,1% a 32,5%), porque a distância muda.
- **Texto livre:** a extração por regras acerta 100% dos campos em pedidos formais, abreviados e com erros de digitação; nos 45 pedidos ambíguos nenhum fica completo, 53% dos campos ficam em branco e 4% saem errados. Por isso a extração nunca chuta: o campo em branco vai para o coordenador, que sempre confere. Dos 60 ataques de injeção de prompt, 60 são sinalizados, sem falso positivo em 340 pedidos normais.

Da análise à decisão

O que a análise mostrou	O que decidimos
A carga recente parece "boa" (correlação positiva), mas é confundimento	Saiu do ranking e virou alerta de jornada; o top-5 fica em 71,2% sem ela e em 71,3% com ela
A distância explica o aceite e funciona como proxy da zona de residência	Fica no ranking (critério operacional), mas a participação por zona é monitorada; mitigação na Etapa 3
O processo manual ignora disponibilidade e jornada: 1,3% dos aceites violam a jornada	O filtro de regras vem antes do ranking e é determinístico

4. Solução de IA



Fluxo da solução

Entrada, processamento de IA, saída e usuário. O coordenador digita a vaga em texto livre; a IA extrai os campos e ele os **confere**; o código filtra os elegíveis e registra a regra que barrou cada excluído; o modelo ranqueia; a explicação sai dos fatores; o coordenador **aprova**; tudo vai para a trilha de auditoria. Detalhes em docs/solucao-ia.md.

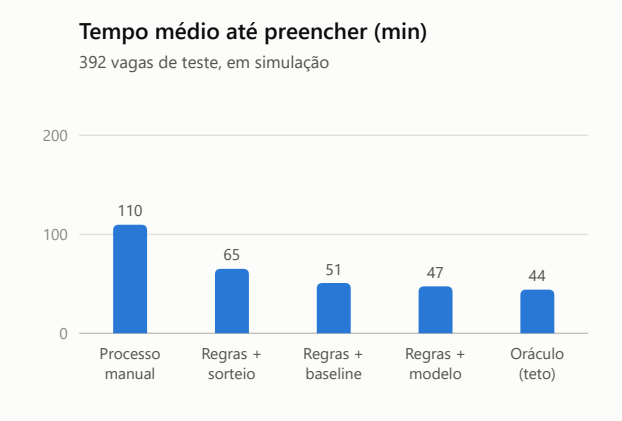
Por que IA e onde não (Excelência Operacional: regra em código, estimativa em ML, linguagem em NLP)

Etapa	Técnica	Por quê, e por que não outra	O que medimos (simulação)
Extração do texto	**NLP** (Gemini) com reserva em regras	Pedidos variam muito; um formulário rígido reduziria a adoção	Regras: 100% em texto formal, abreviado e com erros; Gemini não exercitado
Filtro de elegibilidade e jornada	**Código**	Regra exata e auditável; LLM não é determinístico	0 violações, contra 1,3% no manual; **72% do ganho de tempo**
Ranking	**ML**: regressão logística	Combina sinais e é explicável por peso. LightGBM e scikit-learn não foram testados: perderiam a leitura por peso e a PoC roda sem dependências	+3,5 pontos percentuais no top-5 e 7% menos tempo sobre o baseline heurístico
Explicação	Texto fixo; o LLM só reescreve	Os fatores já são conhecidos; o LLM não pode inventar motivo	Reescrita que acrescenta algo é descartada (testes)
Aprovação	**Humano**	Res. CFM 2.454, Art. 15: a solução não é soberana	Sem clique, sem oferta (testado)

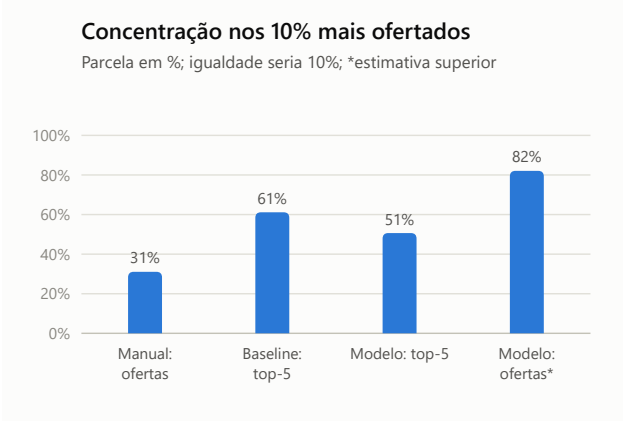
Quanto vale cada parte. O baseline é o que uma coordenação faria "no olho": perto e com a janela cobrindo a vaga. O modelo foi treinado no passado e testado em 392 vagas de agosto e setembro de 2026, com cerca de 50 elegíveis por vaga. O oráculo é o teto (os 5 melhores segundo a verdade do simulador) e o sorteio é o piso; a AUC mede o quanto o ranking separa quem aceita de quem recusa (0,5 é acaso).

Medida	Baseline	Modelo	Oráculo	Sorteio
AUC no teste (ofertas observadas)	0,702	0,762	n/d	n/d
Chance média de sucesso no top-5 (contrafactual)	67,7%	71,2%	75,8%	52,9%

O modelo entrega **3,5 pontos percentuais** a mais que o baseline (erro-padrão 0,22) e 94% do oráculo.



Do processo manual ao oráculo: o ganho de tempo (simulação)



O custo do ganho: ofertas em poucos médicos (simulação)

À esquerda, de onde vem o ganho de tempo: só o filtro de regras (sorteio entre elegíveis) leva o tempo médio de 110 para 65 min, e o modelo chega a 47 min. **72% do ganho vem de não chamar quem não poderia aceitar**; o ranking por modelo acrescenta um ganho real, mas menor. À direita, o custo: recomendar por ordem concentra as ofertas em poucos médicos (seção 6). A medição usa as premissas de tempo do simulador (método e limites).

LLM (Gemini) e proteção contra injeção de prompt. O LLM só extrai campos e reescreve a explicação, **sem ferramentas e sem segredos**; nome, CRM e telefone nem existem no prompt. A defesa tem camadas: limpeza da entrada; texto com sinal de ataque **nunca chega ao LLM**; a saída só vale se passar por um **esquema fechado**; a reescrita não pode acrescentar número, fator nem valor. Cobrimos **10 tipos de ataque** (como ignorar regras, vazar segredo, injetar pagamento, forjar campos e extrair dados pessoais). Falha ou ausência do LLM cai nas regras e no texto fixo.

Ferramentas e custo. Python 3.12 (só biblioteca padrão), pytest, ruff e GitHub Actions: custo zero e nada a instalar. Gemini `gemini-3.5-flash-lite` e `gemini-3.8-flash`: cerca de US$ 0,37 a US$ 0,68 por 200 chamadas (preços do Google em 28/10/2026). FastAPI, Next.js, n8n e Supabase foram **adiados** (ADR 0004); o motor foi feito para ser reaproveitado por eles.

5. Prova de conceito

A PoC mínima roda por linha de comando, sem tela, banco, n8n nem API (ADR 0005). Para rodar:

```
make poc       # dados, modelo, fluxo recomendado, demonstração, exemplo trabalhado e análise
make test      # 176 testes automáticos
make entrega   # este documento, em HTML e PDF
```

No Windows sem `python` no PATH: `make PYTHON="py -3.12" poc`. Saída da demonstração (vaga de pediatria, sexta à noite; as contas estão no exemplo trabalhado):

```
Campos extraídos (fonte: regras): Hospital Modelo Centro | pediatria | sexta 02/10 19h a 03/10 07h | urgência alta
Recomendação logreg-v1 (simulação): 65 elegíveis entre 300 médicos. Top 5:
  1. id f4343f8e  score 0,69  mora a 1,4 km, prefere o período, taxa de aceite estimada de 45%
  4. id d69d231d  score 0,66  ... Atenção (jornada): carga recente alta, 9 plantões em 30 dias
Excluídos pelas regras (235): 131 especialidade diferente | 64 sem disponibilidade
                              25 fora do raio | 15 CRM não ativo
Aprovação (demonstração): 3 aprovados.  Trilha: 9 registros, cadeia de hash íntegra
```

Construído e executando	Desenhado, não construído
Gerador de dados e qualidade; filtro de regras e jornada; 7 variáveis sem vazamento; baseline e modelo; avaliação e fluxo recomendado; explicação; extração por regras; guardrails e 10 tipos de ataque; aprovação humana; trilha com hash	Interface (4 telas desenhadas em wireframes); oferta em cascata no n8n; contestação do médico; banco e RLS; previsão de vagas; teste do Gemini com chave (plano)

Evidências. 176 testes automáticos passam (casos de borda de jornada, 10 tipos de injeção, 12 saídas maliciosas do LLM, verificação da trilha e a matemática da simulação do fluxo), o lint passa e a CI roda a PoC inteira em Linux, em 5 verificações verdes. A trilha de auditoria guarda só IDs pseudônimos e a versão do modelo.

6. Segurança, ética e conformidade

As quatro perguntas de Direito e Ética (as mesmas da Entrega 1, seção 13)

Pergunta	Resposta
Há dados pessoais?	Hoje, não: tudo é sintético. Em produção, sim (veja Cybersecurity)
Há risco de discriminação?	Sim, por proxy: a distância reflete a zona de residência. Gênero, faixa etária e zona ficam fora do ranking e entram na auditoria de viés (abaixo)
A decisão afeta pessoas?	Sim: a renda dos médicos e a cobertura do pronto-socorro. Por isso decide o coordenador, com motivo por recomendação e trilha de auditoria; a contestação do médico está desenhada
Há questões regulatórias?	Sim: Res. CFM 2.454, 2.460 e 2.462, resumidas a seguir

Cybersecurity (detalhe em seguranca-ameacas.md)

Pergunta	Resposta
Quais dados?	Cadastro, agenda, vagas, ofertas, textos livres, valor do plantão (separado) e trilha
Há dados pessoais?	Hoje, **não** (sintéticos). Em produção, sim (CRM, agenda, aceites): LGPD, a validar com jurídico; nome, CRM e telefone nunca vão ao LLM
Onde ficam?	Hoje, CSV local e CI; depois, banco em São Paulo; o LLM recebe só o texto da vaga
Quem acessa?	Hoje, a equipe; depois, RLS por organização e papel (desenho)
Ameaças	Injeção de prompt, saída forjada do LLM, adulteração da trilha, vazamento de dado e de segredo, viés, influência do pagamento
Proteções	Esquema fechado, LLM sem ferramentas, hash encadeado, varredura de segredos, lista fechada de variáveis com teste na CI, decisão humana

Normas, lidas nos textos oficiais em 30/10/2026 (não é parecer jurídico; ficha completa)

Norma	Em vigor?	O que pesa para a plataforma	Como respondemos
Res. CFM 2.454/2026 (IA)	Sim, desde cerca de 26/08/2026 (180 dias após o DOU de 27/02; Art. 23)	A solução "não é soberana" e a supervisão humana é obrigatória (Art. 15); o hospital classifica o risco em baixo, médio, alto ou inaceitável (Art. 12 e 13; Anexo II)	Aprovação do coordenador, trilha, explicação e relatório de disparidade. **Reavaliamos o risco de baixo (Entrega 1) para médio**: o Anexo II cita agendamento como baixo risco, mas o sistema ranqueia pessoas e apoia decisão operacional importante
Res. CFM 2.460/2026 (vantagens econômicas)	Sim, desde 15/06/2026 (Art. 7º)	Veda vantagem econômica ligada à contratação ou ao favorecimento em escala; cita "contribuição para grupo ou plataforma digital" (Art. 2º) e as plataformas (Art. 4º, §2º)	Assinatura fixa paga pelo hospital, sem comissão e sem cobrança ao médico; o pagamento não entra no ranking (teste na CI)
Res. CFM 2.462/2026 (inadimplemento)	**Suspensa:** o PDF oficial traz aviso de suspensão judicial integral (processo 1025417-59.2026.4.01.0000)	Sanções a pessoas jurídicas que não pagam plantões	**Correção da Entrega 1**, que a tratava como em vigor: a plataforma não custodia dinheiro, e o rastro de pagamentos passa a ser evolução futura, sem base normativa afirmada

A 2.454 foi lida em uma cópia em PDF hospedada pela Fiocruz, que avisa não substituir a versão certificada do DOU. **Não lemos** a LGPD, o Tema 1.389 do STF nem normas de jornada: 24 h contínuas e 11 h de descanso são configuração do projeto, não norma verificada. **Pendências para o jurídico:** (1) escopo da 2.454 e quem classifica o risco; (2) risco baixo ou médio; (3) a assinatura fixa frente aos Art. 2º, 4º §2º e 6º da 2.460; (4) situação da suspensão da 2.462 e se a plataforma é "intermediadora"; (5) LGPD: base legal e transferência internacional ao provedor do LLM; (6) vínculo dos médicos em hospital privado (Tema 1.389); (7) limites de jornada.

Viés e concentração. Atributos protegidos ficam fora do ranking, mas a distância funciona como proxy da zona: no top-5, médicos de leste e oeste quase não aparecem (razão de 0,01), e 121 de 257 elegíveis nunca são recomendados. A **concentração é o risco mais sério que medimos**: no processo manual simulado, os 10% de médicos mais ofertados recebem 31,1% das ofertas; no top-5 do modelo ocupam 50,7% dos lugares (61,2% no baseline) e, se a cascata seguir a ordem do ranking, a estimativa chega a 82% das ofertas efetivas (valor superior: cada vaga é avaliada isoladamente). Mitigações para a Etapa 3: rodízio entre elegíveis equivalentes, limite de ofertas por médico, menor peso da distância e revisão humana da lista.

7. Metas, resultados e limites

As metas da Entrega 1 eram pontos de partida. Cada uma ganhou uma linha de base (o processo manual simulado) e um resultado do fluxo recomendado, medidos nas mesmas 392 vagas de teste (método e ADR 0006).

Meta da Entrega 1	Linha de base (manual simulado)	Fluxo recomendado (simulação)	Situação
Tempo médio até preencher: 50% a menos	110 min (mediana 85)	47 min (mediana 38): 57% a menos	**Alcançável em simulação**; 72% do ganho vem do filtro de regras; a linha de base real vem das entrevistas
Preenchidas com 24 h ou mais de antecedência: +20 pontos	70,7% (teto: 76,0% das vagas já nascem assim)	74,8% (+4,1 pontos)	**Não alcançável só com a recomendação**: depende de publicar a vaga antes (previsão de vagas, evolução futura)
Recomendações aceitas pelo coordenador: 60% ou mais	n/d	n/d	**Não mensurável agora**: não há coordenador simulado; teste com usuários na Etapa 3
Previsão de vagas descobertas: recall de 0,7 ou mais	n/d	n/d	**Adiada**: pertence ao módulo de previsão, evolução futura (o feedback pediu priorizar recomendação e explicação)
Violações de jornada: zero	1,3% dos aceites (30 de 2.330)	0	**Atendida**, por construção do filtro e por testes de borda
Ranking influenciado por pagamento: zero	n/d	0	**Atendida**: teste na CI
Concentração de ofertas: monitorar e definir teto	31,1% das ofertas nos 10% mais ofertados	50,7% dos lugares do top-5; até 82% das ofertas efetivas	**Piorou frente ao manual**; teto ainda a definir; mitigar é prioridade da Etapa 3

Indicador novo desta entrega	Como se mede	Baseline	Resultado (simulação)
Qualidade do ranking	Chance de sucesso no top-5 e AUC, em teste temporal	Baseline heurístico: 67,7%; AUC 0,702	71,2% (+3,5 pontos percentuais); AUC 0,762
Fidelidade da explicação	Testes: todo motivo vem do cálculo do modelo; reescrita que acrescenta algo é descartada	n/d	0 motivos inventados nos testes; a utilidade para o coordenador fica para o teste com usuários
Injeção de prompt	10 tipos de ataque, 60 pedidos	n/d	60 de 60 sinalizados; 0 falsos positivos em 340

Como ler. Os resultados são de simulação e valem tanto quanto as premissas do grupo: o processo manual simulado não checa disponibilidade, e um coordenador real pode ser melhor ou pior; só as entrevistas dirão. A meta de reduzir o tempo pela metade fica **alcançável em simulação, a confirmar com dados reais**.

Limites. O modelo aprende o simulador; o Gemini não foi exercitado; a regressão logística não foi comparada com outros modelos; a distância cria viés geográfico; a extração por regras é otimista; contestação e avaliação de impacto estão desenhadas, não construídas; a evidência de mercado (Flexzo) é alegação da empresa e o caso público de Canoas não é do segmento privado.

8. Próximos passos, autoria e uso de IA

Etapa 3 (entrega em 07/11). (1) Entrevistas com 3 a 5 coordenadores e 3 a 5 plantonistas, prometidas na Entrega 1 e ainda não feitas: calibram o simulador e dão a linha de base real do tempo e da antecedência; (2) teste do Gemini com chave, com plano em teste-manual-gemini.md; (3) mitigar a concentração e o viés de distância; (4) parecer jurídico sobre as sete pendências; (5) previsão de vagas e relatório de equidade; (6) interface do coordenador, API e cascata no n8n, se o grupo aprovar.

Autoria e uso de IA. O trabalho foi feito **em conjunto**, em ciclos de proposta, revisão e correção entre o Victor Jordão e o Claude Code (modelo Sonnet 5.5): **nem tudo foi feito pela IA**. A sugestão dos dados partiu do Victor, por exemplo o recorte do mundo simulado (pronto-socorro de hospitais privados, plantão noturno de 12 h e de fim de semana), e as decisões de escopo foram dele, registradas em ADRs (segmento, Gemini como LLM do produto, protótipo adiado, PoC mínima mais material de especificação). O Claude Code ajudou a transformar essas decisões em gerador, código, testes, análises e texto, e o Victor revisou e corrigiu o resultado. O processo também pegou falhas da própria IA, como um motivo "fez 9 plantões" que aparecia a favor do candidato (virou alerta) e uma extração que não reconhecia "ter" como terça-feira. O LLM do produto é o Gemini. Os números deste documento saem de arquivos gerados pelo código, e um teste falha se divergirem.

Referências. Res. CFM 2.454/2026 (DOU), 2.460/2026 e 2.462/2026; Gemini: modelos, preços e termos; Entrega 1.