PlantãoSeguro: Entrega 2 (dados, análise, solução de IA e prova de conceito)

Disciplina: Hands On – Aplicação de IA nos negócios (Mackenzie), Prof. Fabio Versolatto. **Grupo:** Victor Jordão, Roberval Silva, Guilherme Tarrago, Sergio Freitas, Lucas Barbosa e Plinio Camilo. **Entrega:** 31/10/2026. **Código e documentos:** github.com/vhjordao/handson_plantaoseg.

> **Leitura honesta.** Os dados são **sintéticos** e os resultados são **simulação**: o modelo aprende o simulador que gerou os dados, então os números servem para comparar métodos entre si e não provam desempenho no mundo real. O Gemini está desenhado e protegido por testes, mas **não foi exercitado contra o serviço real**.

1. O problema e o segmento

Hospitais ainda cobrem plantões por canais manuais e opacos, o que atrasa a cobertura, aumenta o risco assistencial e expõe as partes a riscos jurídicos novos. O PlantãoSeguro recomenda, de forma **explicável, contestável e auditável**, quais médicos chamar para cada vaga. **A IA recomenda, o humano decide.**

O que mudou desde a Entrega 1, atendendo ao feedback do professor:

- **Segmento definido:** pronto-socorro de hospitais privados, plantão noturno de 12 h e de fim de semana, clínica médica e pediatria (ADR 0001).
- **Núcleo da PoC:** recomendação de médicos elegíveis e explicação das recomendações; os demais módulos são evolução futura (ADR 0002).
- **Metas com linha de base:** o modelo é medido contra um baseline heurístico (seção 7).
- **Normas conferidas nos textos oficiais** (seção 6), o que corrigiu duas afirmações da Entrega 1.
- **LLM do produto:** Gemini (ADR 0003).

Frase-síntese: queremos utilizar IA para recomendar e explicar quais médicos chamar para cada plantão de pronto-socorro, a fim de reduzir o tempo de cobertura sem violar a jornada nem as regras do CFM, beneficiando coordenadores de escala e médicos de hospitais privados, medindo o sucesso pela qualidade do ranking contra um baseline, pelas violações de jornada (meta zero) e pela concentração das ofertas.

2. Dados

Origem e por quê. Ainda não há dado real nem entrevistas. Por isso criamos um mundo simulado de três hospitais privados fictícios de uma rede, com 300 médicos e 12 meses de vagas e de ofertas feitas por um "processo manual" (a coordenação chama médicos em cascata, sem checar a jornada). Isso permite construir e medir o motor sem expor ninguém. Nome, CRM e telefone são fictícios e marcados `SIM`.

Tabela	Linhas	Conteúdo
Médicos	300	Especialidade, raio, preferência, zona, disponibilidade semanal
Janelas de disponibilidade	3.391	Janelas livres e dias bloqueados
Vagas	2.448	Noturnas todos os dias; diurnas só no fim de semana
Ofertas	7.555	Quem foi chamado, resposta e comparecimento
Pedidos em texto livre	400	5 estilos, com gabarito; 15% adversariais
Valor do plantão	2.448	Tabela **separada**, fora do ranking

Variáveis e dicionário. O dicionário de dados (v0.2) dá a cada coluna um **papel** que manda no que ela pode fazer: variável do ranking, auditoria de viés (gênero, faixa etária e zona), restrito econômico, dado pessoal simulado ou gabarito do simulador. O ranking usa **7 variáveis** (especialidade, distância, cobertura da vaga, taxas de aceite e de comparecimento em 90 dias, horas desde o último plantão e preferência de período). Carga recente e exposição são calculadas mas ficam **fora** do ranking.

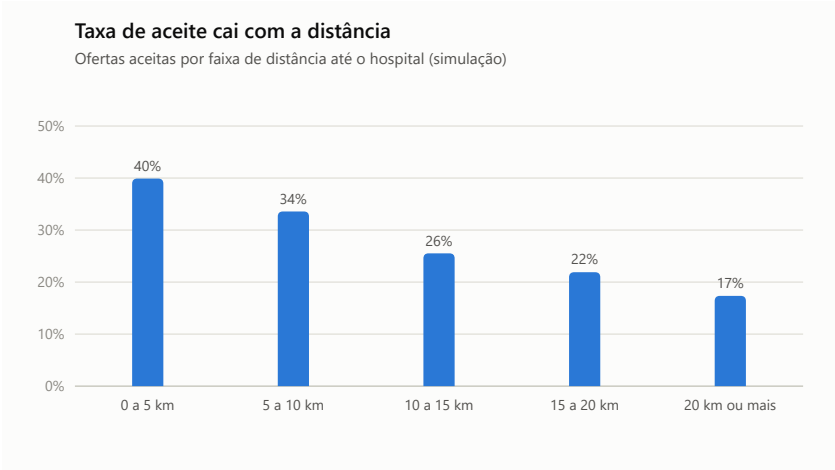
Tratamento e qualidade. As variáveis usam só o que já era conhecido antes de cada oferta (testado: o futuro não vaza). O gerador aplica **8 regras de qualidade** (integridade, domínios, datas, unicidade, coerência,

sobreposição, ausência de dado real, cobertura do segmento) com **zero violações** (relatório). A mesma semente gera os mesmos arquivos: a CI em Linux reproduziu os checksums da máquina do autor em Windows.

Limites. Os parâmetros são premissas do grupo, sem fonte externa; só se observa a resposta de quem foi chamado (viés de seleção); o tempo até preencher a vaga é simulado e não serve de linha de base real. A simulação produziu 3,09 ofertas por vaga, 30,8% de aceite, 4,8% de vagas sem cobertura e 1,3% de aceites que violam a jornada.

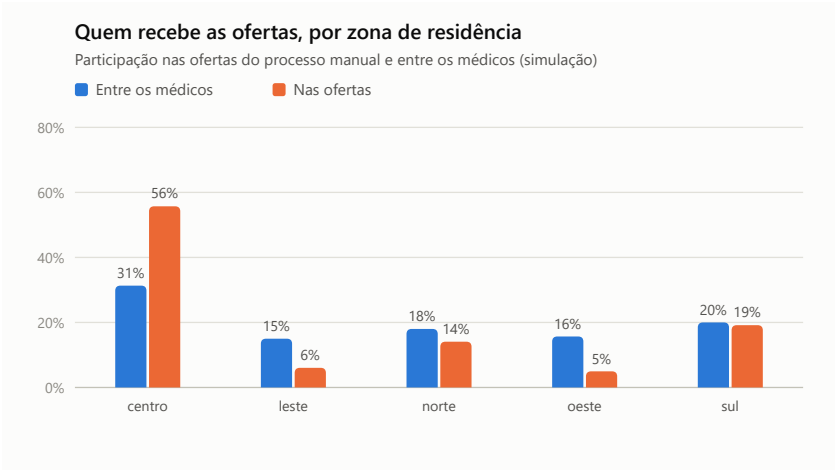
3. Análise dos dados

A análise exploratória mostra o que o simulador contém e onde mora o risco.



Taxa de aceite por faixa de distância (simulação)

- **O aceite cai com a distância:** 39,9% a 0 a 5 km e 17,4% a 20 km ou mais. Quando a preferência de período coincide, o aceite vai a 37,0% (vaga noturna) contra 18,1% quando não coincide.
- **Descanso:** 22,3% de aceite quando o plantão é colado a outro e 42,4% com 72 a 167 h livres. Plantões de 12 h em horários fixos nunca deixam um intervalo menor que 11 h, então essa regra quase não aparece nos dados; o limite de 24 h contínuas, sim.
- **Correlação com o sucesso:** cobertura da vaga (0,370), preferência de período (0,200) e distância (-0,156) lideram. A carga recente tem correlação positiva (0,069), por confundimento (quem é confiável aceita mais), o que motivou tirá-la do ranking.

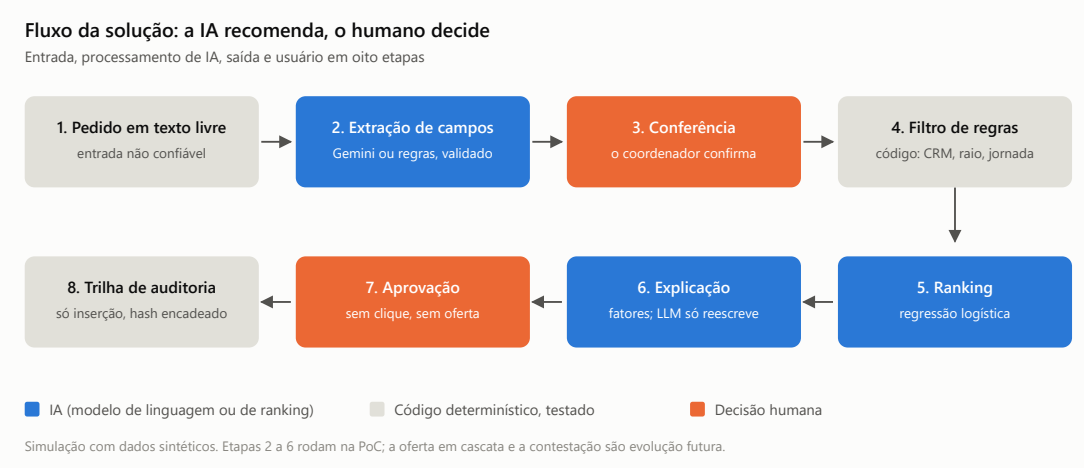


Exposição das ofertas por zona de residência (simulação)

- **Exposição desigual (o risco do exemplo de recrutamento):** a zona central tem 31,3% dos médicos e recebe 55,7% das ofertas; leste e oeste recebem 0,40 e 0,32 do esperado. Entre 35 e 44 anos a razão é 1,49 e, a partir de 55, 0,39. Por gênero, a razão é praticamente 1. O aceite por grupo é parecido por gênero (30,2% a 31,4%) e varia por zona (23,1% a 32,5%) porque a distância muda.
- **Texto livre:** a extração por regras acerta 100% dos campos em pedidos formais, abreviados e com erros de digitação; nos 45 pedidos ambíguos nenhum fica completo, 53% dos campos ficam em branco para o

coordenador e 4% saem errados. Dos 60 ataques de injeção de prompt, 60 são sinalizados, sem falso positivo em 340 pedidos normais.

4. Solução de IA



Fluxo da solução

Entrada, processamento de IA, saída e usuário. O coordenador digita a vaga em texto livre; a IA extrai os campos e ele os **confere**; o código filtra os elegíveis e a regra que barrou cada excluído; o modelo ranqueia; a explicação sai dos fatores; o coordenador **aprova**; tudo vai para a trilha de auditoria. Detalhes em docs/solucao-ia.md.

Por que IA e onde não (Excelência Operacional: automatizar regra, usar ML para estimativa, NLP para linguagem):

Etapa	Técnica	Por quê, e por que não outra
Extração do texto	**NLP** (Gemini) com fallback em regras	Pedidos variam muito; formulário rígido reduziria a adoção
Filtro de elegibilidade e jornada	**Código**	Regra exata e auditável; LLM não é determinístico
Ranking	**ML**: regressão logística	Combina sinais; é explicável por peso. LightGBM e scikit-learn não mostraram ganho necessário
Explicação	Texto fixo; LLM só reescreve	Os fatores já são conhecidos; o LLM não pode inventar motivo
Aprovação	**Humano**	Res. CFM 2.454, Art. 15: a solução não é soberana

Ranking e resultado (simulação). O baseline é o que uma coordenação faria no olho: perto e com a janela cobrindo a vaga. O modelo foi treinado no passado e testado em 392 vagas de agosto e setembro de 2026, com cerca de 50 elegíveis por vaga.

Medida	Baseline	Modelo	Oráculo	Sorteio
AUC no teste (ofertas observadas)	0,702	0,762	n/d	n/d
Chance média de sucesso no top-5 (contrafactual)	67,7%	71,2%	75,8%	52,9%

O modelo entrega **3,5 pontos percentuais** a mais que o baseline (erro-padrão 0,22) e 94% do oráculo. A avaliação contrafactual só é possível porque o simulador conhece a chance verdadeira de cada médico. Um experimento mostrou que **tirar a carga recente do ranking não custa nada** (71,2% com e sem ela), enquanto evita recomendar o mais sobrecarregado; ela virou **alerta de jornada**.

LLM (Gemini) e proteção contra injeção de prompt. O LLM só extrai campos e reescreve a explicação, **sem ferramentas e sem segredos**; nome, CRM e telefone nem existem no prompt. A defesa tem camadas: limpeza da entrada; texto com sinal de ataque **nunca chega ao LLM**; a saída só vale se passar por um **esquema fechado**; a reescrita não pode acrescentar número, fator nem valor. Cobrimos **10 tipos de ataque** (ignorar regras, vazar segredo, injetar pagamento, forjar campos, texto gigante, caracteres de controle, troca de idioma,

papel falso, extração de dados pessoais e vazamento do prompt). Falha ou ausência do LLM cai nas regras e no texto fixo.

Ferramentas e custo. Python 3.12 (só biblioteca padrão), pytest, ruff e GitHub Actions: custo zero e nada a instalar. Gemini `gemini-3.5-flash-lite` e `gemini-3.8-flash`: cerca de US$ 0,37 a US$ 0,68 por 200 chamadas (preços do Google em 28/10/2026). FastAPI, Next.js, n8n e Supabase foram **adiados** (ADR 0004); o motor foi feito para ser reaproveitado por eles.

5. Prova de conceito

A PoC mínima roda por linha de comando, sem tela, banco, n8n nem API (ADR 0005). `make poc` gera os dados, treina e avalia o modelo, roda a demonstração, o exemplo trabalhado e a análise. Saída da demonstração (vaga de pediatria, sexta à noite; ver o exemplo trabalhado com as contas):

```
Campos extraídos (fonte: regras): Hospital Modelo Centro | pediatria | sexta 02/10 19h a 03/10 07h | urgência alta
Recomendação logreg-v1 (simulação): 65 elegíveis entre 300 médicos. Top 5:
  1. id f4343f8e  score 0,69  mora a 1,4 km, prefere o período, taxa de aceite estimada de 45%
  4. id d69d231d  score 0,66  ... Atenção (jornada): carga recente alta, 9 plantões em 30 dias
Excluídos pelas regras (235): 131 especialidade diferente | 64 sem disponibilidade
                              25 fora do raio | 15 CRM não ativo
Aprovação (demonstração): 3 aprovados.  Trilha: 9 registros, cadeia de hash íntegra
```

Construído e executando	Desenhado, não construído
Gerador de dados e qualidade; filtro de regras e jornada; 7 variáveis sem vazamento; baseline e modelo; avaliação; explicação; extração por regras; guardrails e 10 tipos de ataque; aprovação humana; trilha com hash	Interface (4 telas em wireframes); oferta em cascata no n8n; contestação do médico; banco e RLS; previsão de vagas; teste do Gemini com chave (plano)

Evidências. Todos os testes automatizados passam (inclusive casos de borda de jornada, 10 tipos de injeção, 12 saídas maliciosas do LLM e a verificação da trilha), o lint passa e a CI roda a PoC inteira em Linux em 5 verificações verdes. A trilha de auditoria guarda só IDs pseudônimos e a versão do modelo.



Tela de recomendação (wireframe de baixa fidelidade, não funcional)

6. Segurança, ética e conformidade

Cybersecurity (detalhe em seguranca-ameacas.md):

Pergunta	Resposta
Quais dados?	Cadastro, agenda, vagas, ofertas, textos livres, valor do plantão (separado) e trilha
Há dados pessoais?	Hoje, **não** (sintéticos). Em produção, sim: LGPD, a validar com jurídico
Onde ficam?	Hoje, CSV local e CI; depois, banco em São Paulo; o LLM recebe só o texto da vaga
Quem acessa?	Hoje, a equipe; depois, RLS por organização e papel (desenho)
Ameaças	Injeção de prompt, saída forjada do LLM, adulteração da trilha, vazamento de dado e de segredo, viés, influência do pagamento

Pergunta	Resposta
Proteções	Esquema fechado, LLM sem ferramentas, hash encadeado, varredura de segredos, lista fechada de variáveis com teste na CI, decisão humana

Normas, lidas nos textos oficiais em 30/10/2026 (conformidade; **não é parecer jurídico**):

- **Res. CFM 2.454/2026 (IA):** a solução "não é soberana" e a supervisão humana é obrigatória (Art. 15); instituições classificam o risco em baixo, médio, alto ou inaceitável (Art. 12 e 13). **Reavaliamos o risco de baixo (Entrega 1) para médio**: o Anexo II cita agendamento como baixo risco, mas o sistema ranqueia pessoas e apoia decisão operacional importante. A classificação formal é do hospital.
- **Res. CFM 2.460/2026 (vantagens econômicas):** o Art. 2º cita "contribuição para grupo ou plataforma digital" e o Art. 4º, §2º, as plataformas. Nosso desenho cobra **assinatura fixa do hospital**, sem comissão e sem cobrança ao médico, e o pagamento não entra no ranking (teste na CI). O enquadramento é questão jurídica.
- **Res. CFM 2.462/2026 (inadimplemento):** o PDF oficial traz aviso de **suspensão judicial integral**. A Entrega 1 a tratava como em vigor; corrigimos, e o rastro de pagamentos passa a ser evolução futura sem base normativa afirmada.

Viés (exigência do exemplo de recrutamento). Atributos protegidos ficam fora do ranking, mas a distância funciona como proxy da zona: no top-5, médicos de leste e oeste quase não aparecem (razão de 0,01). Os 10% mais recomendados ocupam 50,7% dos lugares do modelo (61,2% no baseline) e 121 de 257 elegíveis nunca são recomendados. Mitigações a estudar: limitar o peso da distância, rodízio entre elegíveis equivalentes e revisão humana da lista.

7. Metas, resultados e limites

Indicador	Como se mede	Linha de base	Resultado (simulação)
Qualidade do ranking	Chance de sucesso no top-5 e AUC, teste temporal	Baseline heurístico	+3,5 pontos percentuais; AUC 0,762 contra 0,702
Violação de jornada nas recomendações	Testes do filtro	n/d	0
Ranking influenciado por pagamento	Teste na CI	n/d	0
Concentração de ofertas	Parcela do top-5 dos 10% mais recomendados	Baseline: 61,2%	50,7% (referência igualitária: 10%)
Injeção de prompt	10 tipos, 60 pedidos	n/d	60 de 60 sinalizados
Tempo de preenchimento (meta de reduzir 50%)	**Não mensurável** em dados sintéticos	Entrevistas (Etapa 3)	Hipótese a validar
Recall de 0,7	Pertence à previsão de vagas (Etapa 3)	n/d	Reformulada

Limites. O modelo aprende o simulador; o Gemini não foi exercitado; a distância cria viés geográfico; a extração por regras é otimista (textos de modelo); contestação e avaliação de impacto estão desenhadas, não construídas; 24 h contínuas e 11 h de descanso são configuração do projeto, não norma verificada; a evidência de mercado (Flexzo) é alegação da empresa e o caso público de Canoas não é do segmento privado.

8. Próximos passos e uso de IA

Etapa 3: entrevistas para calibrar o simulador e medir a linha de base real; teste do Gemini com chave; API e tela do coordenador; cascata no n8n; contestação; previsão de vagas e relatório de equidade; mitigar o viés de distância; parecer jurídico sobre classificação de risco, 2.460 e 2.462.

Uso de IA no desenvolvimento. O código, os testes e os documentos foram escritos com o Claude Code (modelo Sonnet 5.5) sob decisões do grupo, registradas em ADRs, e o produto usa o Gemini. O processo corrigiu falhas da própria IA: um motivo "fez 9 plantões" que aparecia a favor do candidato (virou alerta), um

gerador de textos que errava o período e uma extração que não reconhecia "ter" como terça-feira. Os números deste documento saem dos arquivos gerados e um teste falha se divergirem.

Referências. Entrega 1; Res. CFM 2.454/2026 no Diário Oficial; Res. CFM 2.460/2026; Res. CFM 2.462/2026; documentação do Gemini: modelos, preços e termos.